

国债期货量化系列四：

基于多种深度学习模型的策略框架探讨



报告日期：2023 年 03 月 28 日

★主要内容

本文我们探讨目标收益波动率下的深度学习模型应用，探讨多品种量化策略配置框架，基于不同模型进行的仓位预测，得到最优配置。

模型构建方面，我们选择直接预测仓位，解释变量基于相关量价、基差、宏观和利率期限结构特征。采用深度学习模型（自编码器，长短期记忆网络，门循环单元，卷积神经网络）结合的方式，探讨建模流程。

报告比较了特征分类 PCA 降维以及单特征回归挑选显著特征进行 SAE 降维之后，再将降维后的新特征放入深度学习模型进行训练两种降维方法：对于十年期国债期货（T）来说，PCA 降维总体效果优于 SAE；对于五年期国债期货（TF）来说，对夏普损失优化模型 SAE 降维总体效果优于 PCA，对方误差损失优化模型 PCA 降维总体效果优于 SAE；对于国债期货价差（2TF-T）来说，PCA 降维总体效果优于 SAE。

混合模型策略方面，报告推荐采用多模型混合策略：资金分配 70% 于 T 的 SAE+LSTM_GRU 均方误差损失优化模型（T 交易最活跃），资金分配 15% 于 TF 的 PCA+GRU 均方误差损失优化模型，以及资金分配 15% 于 2TF-T 的 LSTM 均方误差损失优化模型。我们将 2015-9-9 至 2022-10-20 的混合策略表现作为其初始集，将未参与策略挑选的 2022-10-20 至 2023-3-8 的混合策略表现作为跟踪集，并将混合品种投资（ $1/3 T + 1/3 TF + 1/3 (2TF-T)$ ）作为比较的业绩基准。我们可以看见混合策略在 2 倍，2.5 倍以及 3 倍杠杆下，初始集上的夏普比率均为 1.28，优于业绩基准的 0.63；在跟踪集上的夏普比率分别为 1.31，1.33，1.34，优于业绩基准的 0.32，混合策略整体净值曲线也较为平滑。

★风险提示

量化模型有效性基于历史数据得出，不排除失效的可能。

王冬黎 金融工程首席分析师
从业资格号：F3032817
投资咨询号：Z0014348
Tel: 8621-63325888-3975
Email: dongli.wang@orientfutures.com

联系人：
范沁璇 金融工程助理分析师
从业资格号：F03111965
Email: qinxuan.fan@orientfutures.com

目录

1. 深度学习模型介绍.....	4
1.1. 堆栈式自编码器 (SAE) 模型介绍.....	4
1.2. 循环神经网络模型 (RNN)	5
1.3. 卷积神经网络 (CNN)	8
1.4. 随机失活 (DROPOUT)	9
1.5. 神经网络全连接层 (DENSE)	10
2. 策略框架介绍.....	10
2.1. 数据说明及策略简析.....	11
2.2. 特征提取及特征转换.....	12
2.3. 损失函数介绍.....	12
2.4. 模型结构介绍.....	13
2.5. 模型调参介绍.....	13
3. 模型结果.....	16
3.1. 损失函数结果对比.....	16
3.2. 降维结果比较评估.....	21
3.3. 多模型混合策略展示.....	28
4. 风险提示.....	30

图表目录

图表 1: 自编码器 (AE)	4
图表 2: 堆栈式自编码器 (SAE)	5
图表 3: 循环神经网络结构图	5
图表 4: 简单循环神经网络节点结构图	6
图表 5: 长短期记忆网络节点结构图	7
图表 6: 门控循环单元节点结构图	8
图表 7: 典型卷积神经网络结构示意图	8
图表 8: 模型结构设置	13
图表 9: 十年期国债期货 (T) 模型参数设置	14
图表 10: 五年期国债期货 (TF) 模型参数设置	15
图表 11: 国债期货价差 (2TF-T) 模型参数设置	15
图表 12: 损失函数结果比较	16
图表 13: 十年期国债期货 (T) 业绩基准表现指标	17
图表 14: 十年期国债期货 (T) 各模型表现指标	18
图表 15: 五年期国债期货 (TF) 业绩基准表现指标	18
图表 16: 五年期国债期货 (TF) 各模型表现指标	19
图表 17: 国债期货价差 (2TF-T) 业绩基准表现指标	20
图表 18: 国债期货价差 (2TF-T) 各模型表现指标	20
图表 19: 十年期国债期货 (T) 降维情况比较	21
图表 20: 十年期国债期货 (T) 主成分分析降维后各模型表现指标	22
图表 21: 十年期国债期货 (T) 堆栈自编码器降维后各模型表现指标	23
图表 22: 五年期国债期货 (TF) 降维情况比较	24
图表 23: 五年期国债期货 (TF) 主成分分析降维后各模型表现指标	24
图表 24: 五年期国债期货 (TF) 堆栈自编码器降维后各模型表现指标	25
图表 25: 国债期货价差 (2TF-T) 降维情况比较	26
图表 26: 国债期货价差 (2TF-T) 主成分分析降维后各模型表现指标	27
图表 27: 国债期货价差 (2TF-T) 堆栈自编码器降维后各模型表现指标	28
图表 28: 业绩基准指标	29
图表 29: 混合策略指标	29
图表 30: 混合策略净值曲线	29

1. 深度学习模型介绍

本报告进行了深度学习模型在时序数据上的实证研究，采用结构包括堆栈式自编码器（SAE），长短期记忆网络（LSTM），门循环单元（GRU），卷积神经网络（CNN），随机失活（DROPOUT）以及全连接层（DENSE）。

报告参考神经网络相关的论文包括：A deep learning framework for financial timeseries using stacked autoencoders and long short term memory（采用小波转换，堆栈式自编码器以及长短期记忆网络进行股票的价格预测。具体做法是先用小波转换降噪，然后采用堆栈式自编码器将输入的数据生成高级的特征，最后将这些特征放入长短期记忆网络模型进行预测）；Dropout: A Simple Way to Prevent Neural Networks from Overfitting（我们可以采用随机扔去一些神经元来避免过拟合）；Enhancing the momentum strategy through deep regression（研究一些现有的动量策略，利用堆栈式自编码器增加利润并获得其他理想属性，深度学习可以改进这些动量策略）；Enhancing Time Series Momentum Strategies Using Deep Neural Networks（夏普优化的长短期记忆网络在没有交易成本的情况下将传统方法提高了两倍以上）等。

1.1. 堆栈式自编码器（SAE）模型介绍


自编码器（AE）是一种人工神经网络，自编码器模型主要由编码器（Encoder）和解码器（Decoder）组成，其主要目的是将输入 x 转换成中间变量，然后再将中间变量转换成新变量，然后对比输入 x 和输出新变量使得他们两个无限接近来进行训练。

自编码器是一种无监督学习，它可以学习到输入数据的隐含特征，同时用学习到的新特征可以重构出原始输入数据。自动编码器可以用于特征降维，类似主成分分析 PCA，但是其相比 PCA 其性能更强，这是由于神经网络模型可以提取更有效的新特征。

根据上面介绍，自编码器看作由两个级联网络组成：第一个网络是一个编码器，负责接收输入 x ，并将输入通过函数 h 变换为信号 y ；第二个网络将编码的信号 y 作为其输入，通过函数 f 得到重构的信号 r ，数学表达式如下：

$$\begin{aligned} \text{encoder: } y &= h(x) \\ \text{decoder: } r &= f(y) = f(h(x)) \end{aligned}$$


图表 1：自编码器（AE）



资料来源：东证衍生品研究院

堆栈式自编码器通过堆叠自编码器构建深度网络模型，使用逐层贪婪训练法依次训练每层网络，从像素层面无监督学习特征，避免传统神经网络等方法需进行人工特征分析与选取的问题。因此，堆栈式自编码器本质上就是增加自动编码器中间特征的层数。

图表 2：堆栈式自编码器 (SAE)



资料来源：东证衍生品研究院

以本报告的堆栈结构为例，在两次编码器之后又进行了两次解码，数学表达式如下：

$$\text{encoder1: } y = h(x)$$

$$\text{encoder2: } k = g(y)$$

$$\text{decoder1: } s = f(k)$$

$$\text{decoder2: } r = m(s) = m(f(g(h(x))))$$


在本报告中，我们定义误差为原始输入 x 与重构信号 r 之差，网络训练的损失函数为均方误差 (MSE)：

$$L = \sum_{i=1}^n (x - r)^2$$

1.2. 循环神经网络模型 (RNN)

在处理时间序列的深度学习问题时，循环神经网络 (RNN) 是最常用的模型之一。模型可以在深度学习中处理一系列输入，并在处理下一个输入序列时保留其状态。传统的神经网络处理输入时，不考虑顺序。但金融数据多为时间序列，具有顺序，传统的前馈网络无法理解这一点，而在循环神经网络的设置中，每个输入都依赖于先前的输入。

图表 3：循环神经网络结构图

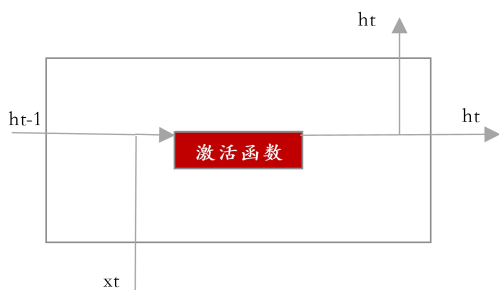


资料来源：东证衍生品研究院

简单循环神经网络的数学表达式为：

$$h_t = f(W \cdot [h_{t-1}, x_t] + b) = f(w_{xt}x_t + w_{ht}h_{t-1} + b)$$

图表 4：简单循环神经网络节点结构图



资料来源：东证衍生品研究院

在简单循环神经网络中，“长期依赖”问题是普遍存在的。长期依赖产生的原因是当神经网络的节点经过许多阶段的计算后，之前比较长的时间片的特征已经被覆盖。随着数据时间片的增加，循环神经网络丧失了学习较远的信息的能力。

梯度消失和梯度爆炸是困扰循环神经网络模型训练的关键原因之一，产生梯度消失和梯度爆炸是由于循环神经网络的权值矩阵循环相乘导致的，相同函数的多次组合会导致极端的非线性行为。处理梯度爆炸可以采用梯度截断的方法。所谓梯度截断是指将梯度值超过阈值的梯度手动降到阈值，虽然梯度截断会一定程度上改变梯度的方向，但梯度截断的方向依旧是朝向损失函数减小的方向。对比梯度爆炸，梯度消失不能简单的通过类似梯度截断的阈值式方法来解决，因为长期依赖的现象也会产生很小的梯度。比如我们希望 t_n 时刻能够读到 t_1 时刻的特征，在这期间内我们自然不希望隐层节点状态发生很大的变化，所以 t_2 至 t_8 的梯度要足够小，如果刻意提高小梯度的值将会使模型失去捕捉长期依赖的能力。

而长短期记忆网络（LSTM）与门控循环单元（GRU）可以解决上述问题，它们均引入了门（gate）机制用于控制特征的流通和损失。

长短期记忆网络的核心部分是在节点中最上边类似于传送带的部分，这一部分一般叫做单元状态（cell state）它自始至终存在于长短期记忆网络的整个链式系统中。

我们假设遗忘门函数结果为 f_t ，激活函数结果为 i_t ，输出门函数结果为 o_t ，则输出的 C_t 表达式为：

$$C_t = C_{t-1} \times f_t + i_t \times m_t$$

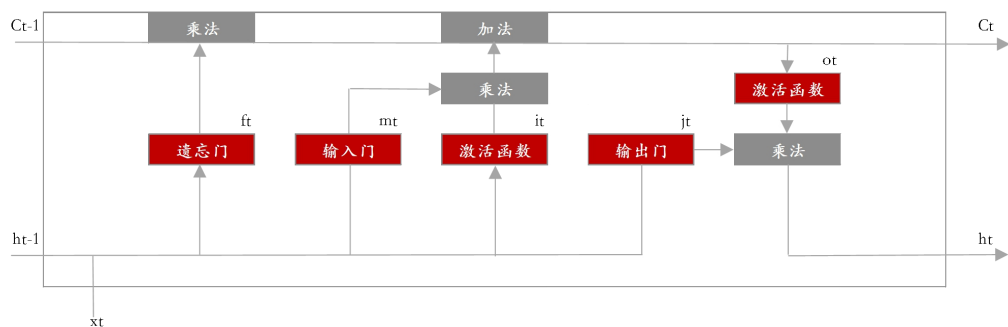
输出的 h_t 的表达式为：

$$h_t = j_t \times o_t$$

其中遗忘门函数，激活函数，输入门函数，输出门函数（a, b, c, d 为自定义函数）表达式为：

$$\begin{aligned} f_t &= a(W_f \cdot [h_{t-1}, x_t] + b_f) \\ i_t &= b(W_i \cdot [h_{t-1}, x_t] + b_i) \\ m_t &= c(W_m \cdot [h_{t-1}, x_t] + b_m) \\ j_t &= d(W_o \cdot [h_{t-1}, x_t] + b_j) \\ o_t &= b(C_t) \end{aligned}$$

图表 5：长短期记忆网络节点结构图



资料来源：东证衍生品研究院

门控循环单元模型作为长短期记忆网络的一种变体，将遗忘门和输入门合成了一个单一的更新门。同样还混合了一些改动，最终的模型比标准的长短期记忆网络模型简单，在训练过程中更节省时间。

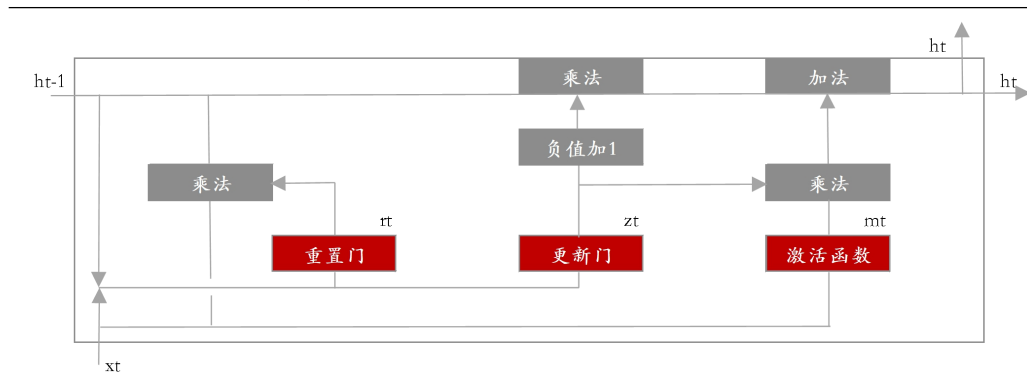
门控循环单元的核心部分是在节点中最上方计算 h_t 的部分，我们假设更新门函数结果为 z_t ，重置门函数结果为 r_t ，激活函数结果为 m_t ，那么 h_t 的数学表达式为：

$$h_t = (-z_t + 1) \times h_{t-1} + z_t \times m_t$$

其中更新门函数，重置门函数以及激活函数（a, b, c 为自定义函数）表达式为：

$$\begin{aligned} z_t &= a(W_z \cdot [h_{t-1}, x_t] + b_z) \\ r_t &= b(W_r \cdot [h_{t-1}, x_t] + b_r) \\ m_t &= c(W_m \cdot [r_t \times h_{t-1}, x_t] + b_m) \end{aligned}$$

图表 6：门控循环单元节点结构图




资料来源：东证衍生品研究院

1.3. 卷积神经网络 (CNN)

卷积神经网络主要是用于处理图像的人工智能模型，它可以把大量参数降维成少量参数，再做处理。典型的卷积神经网络由 3 个部分构成：卷积层，池化层和全连接层。卷积层负责提取图像中的局部特征；池化层主要作用是下采样，用来大幅降低参数量级；全连接层类似传统神经网络的部分，用来输出想要的结果。

图表 7：典型卷积神经网络结构示意图



资料来源：东证衍生品研究院

矩阵卷积有两种：全卷积(full convolution)和有效值卷积(valid convolution)。

全卷积定义式为：

$$z(u, v) = \sum_{i=-\infty}^{\infty} \sum_{j=-\infty}^{\infty} x_{i,j} \cdot k_{i-j, v-j}$$

假设 X 是 $m \times m$ 阶矩阵，K 是 $n \times n$ 阶矩阵，Krot 是由 K 旋转 180° 得到的矩阵，则有效值卷积定义式为：

$$z(u, v) = \sum_{i=-\infty}^{\infty} \sum_{j=-\infty}^{\infty} x_{i+u, j+v} \cdot k_{rot \ i, j} \cdot \chi(i, j)$$

$$\chi(i, j) = \begin{cases} 1, & 0 \leq i, j \leq n \\ 0, & \text{others} \end{cases}$$

假设 f 为激活函数，则卷积层在激活函数后的输出结果 A 为：

$$A(a_{u,v}) = f\left(\sum_{i=-\infty}^{\infty} \sum_{j=-\infty}^{\infty} x_{i+u, j+v} \cdot k_{rot \ i, j} \cdot \chi(i, j) + b\right)$$

$$\chi(i, j) = \begin{cases} 1, & 0 \leq i, j \leq n \\ 0, & \text{others} \end{cases}$$

池化分为平均池化(average pooling)和最大池化(max pooling)。如果使用平均池化，使用的卷积核中每一个单元的权重(weight)都是 $1/\text{卷积核大小均值}$ ，如果采用最大池化的方法，使用的卷积核中其中一个单元的权重是 1 ，其余全部是 0 。

以平均池化为例，已知上一卷积层输出的结果为 $\Lambda[(m-n+1)/r \times (m-n+1)/r \text{ 阶矩阵}]$ ，假设使用卷积核每个单元权重都是 w ，假设激活函数为 g ，则池化层输出结果 B 为：

$$B = g\left(w \sum_{u=ir}^{(i+1)r-1} \sum_{v=ir}^{(j+1)r-1} a_{u,v} + b\right)$$

卷积神经网络在时间序列数据建模上运用较少，一般是作为处理数据中间层和循环神经网络模型合并使用，用一维或二维卷积层连接池化层来进行特征的提取和降维。

1.4. 随机失活 (DROPOUT)

在2012年，Hinton在其论文《Improving neural networks by preventing co-adaptation of feature detectors》中提出随机失活。当一个复杂的前馈神经网络被训练在小的数据集时，容易造成过拟合。为了防止过拟合，可以通过阻止特征检测器的共同作用来提高神经网络的性能。

随机失活的原理为，在每个训练批次中，通过忽略一定比例的特征检测器（让一定比例的隐层节点值为0），可以明显地减少过拟合现象。这样，在前向传播的时候，让某个神经元的激活值以一定的概率停止工作，这样可以使模型泛化性更强，因为它不会太依赖某些局部的特征。

随机失活需要在训练网络的单元添加一个服从伯努利分布的概率矩阵，对应的数学表达式变化如下：

原表达式：

$$y_i^{l+1} = f(W_i^{l+1} y^l + b_i^{l+1})$$

新表达式：

$$r_i^l \sim \text{Bernoulli}(p)$$

$$y_i^{l+1} = f(W_i^{l+1} (y^l \cdot r^l) + b_i^{l+1})$$

随机失活可以减少神经元之间复杂的共适应关系：因为随机失活程序导致两个神经元不一定每次都在一个网络中出现。这样权值的更新不再依赖于有固定关系的隐含节点的共同作用，阻止了某些特征仅仅在其它特定特征下才有效果的情况。迫使网络去学习更

加鲁棒性 (Robust) 的特征，这些特征在其它的神经元的随机子集中也存在。在添加了随机失活的神经网络，在做出某种预测不会对一些特定的线索片段太过敏感，即使丢失特定的线索，它也应该可以从众多其它线索中学习一些共同的特征。

1.5. 神经网络全连接层 (DENSE)

全连接层，是每一个结点都与上一层的所有结点相连，用来把前边提取到的特征综合起来。全连接的核心操作就是简单的矩阵向量乘积，把 f 视为激活函数，那么全连接层的数学表达式如下：

$$y = f(Wx + b)$$

W 是在数据的目标域的空间当中挑选出的几个向量作为列向量，然后由这几个列向量的权重矩阵。这个矩阵的作用就是把输入的数据从它原来所处的空间投影到权重矩阵的列空间 (column space) 当中。这个矩阵的作用就是把输入的数据从它原来所处的空间投影到权重矩阵的列空间当中。

因此，全连接层的本质就是由一个特征空间线性变换到另一个特征空间。目标空间的任一维 (隐层的一个神经元)，都会受到源空间的每一维的影响。只有当列空间尽可能多地涵盖数据的目标域所处的空间，全连接层的训练过程理论上来说才能收敛。

2. 策略框架介绍

本报告改良了 Keras 机器学习框架，创新性使用了自定义的夏普损失函数来对模型进行优化，此外也对深度学习的神经结构进行了探索。报告中，我们以国债期货为例，对模型的效果进行展示。

策略框架中，十年期国债期货 (T) 以 2015-3-27 至 2020-7-9 数据为训练集，2020-7-10 至 2021-8-24 数据为测试集，2021-8-25 至 2022-10-20 数据为跟踪集；五年期国债期货 (TF) 以 2013-9-13 至 2020-1-21 数据为训练集，2020-1-22 至 2021-6-8 数据为测试集，2021-6-9 至 2022-10-21 数据为跟踪集；国债期货跨品种价差 (2TF-T) 以 2015-9-9 至 2020-8-27 数据为训练集，2020-8-28 至 2021-9-17 数据为测试集，2021-6-9 至 2022-10-21 数据为跟踪集。

对于策略的回测，我们假设滑点为 0，无风险利率为 0，对于策略的表现评估我们以相同回测时间内的业绩基准为参照对象。

传统的机器学习主要关注如何学习一个预测模型。一般需要首先将数据表示为特征 (Feature) 或者根据数据挖掘特征，特征的表现形式可以是连续的数值、离散的符号或其他形式。然后将这些特征输入到模型，并输出预测结果。

本报告模型应用包含以下几个步骤：

- (1) 数据预处理：对数据的原始形式进行初步的数据清理 (比如去掉一些有缺失特征的样本，或去掉一些冗余的数据特征等) 和加工 (对数值特征进行缩放和归一化等)，并构建可用于训练机器学习模型的数据集。

- (2) 特征提取：从数据的原始特征中提取一些对特定机器学习任务有用的高质量特征。比如在图像分类中提取边缘、尺度不变特征变换（Scale Invariant Feature Transform, SIFT）特征，在文本分类中去除停用词等。
- (3) 特征转换：对特征进行进一步的加工，比如降维和升维。很多特征转换方法也都是机器学习方法。降维包括特征抽取（Feature Extraction）和特征选择（Feature Selection）等两种途径。常用的特征转换方法有主成分分析（Principal Components Analysis, PCA）、线性判别分析（Linear Discriminant Analysis, LDA），自编码器（Autoencoder, AE）等。
- (4) 预测：机器学习的核心部分，学习一个模型并进行预测。

2.1. 数据说明及策略简析

我们希望根据前五日的数据（量价/基差/利率期限结构）预测和优化后一日的仓位情况。在多品种我们采用的被解释变量为 20 日波动率调整后日收益率。波动率调整表达式为日收益率除以过去日收益率 20 日的滚动波动率：

$$r_{adjusted} = \frac{r}{std_{past_20_days}}$$

我们对不同品种收益进行 20 日波动率归一化的原因是：在模型仓位优化中，我们希望与波动率结合考虑仓位中的杠杆。

在模型应用中，我们采用的输入特征共 3372 个，包含量价特征，基差特征，宏观特征以及利率期限结构特征等。我们对特征的预处理主要采用标准化的方式，我们利用训练集的标准化模型对全数据集进行了转换。

我们通过控制和优化对不同品种的投资杠杆来达到控制仓位的目的。夏普损失优化的模型是通过使用 20 日波动率调整后日收益率，来获得实际仓位为仓位与波动率之积，通过不断优化夏普损失，最终输出最优的仓位。

策略应用方面，我们需要设定模型在单品种的投资上限，根据模型估计结果调整仓位，达到实际交易可以使用的仓位，这样对模型预测结果的回测才有意义。我们希望最终策略达到目标收益的波动率在 20% 以内，因此十年期国债期货，五年期国债期货以及国债期货价差的杠杆上限均约为 2 倍。

因此在模型结果相对交易信号的转化中，我们只要将模型预测的仓位信号分别转化在各自杠杆上限以内，即可控制收益率波动至目标。对于夏普优化模型，具体转化方法我们采用简单的线性伸展：我们根据训练集预测仓位的 75% 分位数作为伸展系数，对于预测仓位在伸展系数以内的情况，我们将仓位等量缩放到 0 至杠杆上限；对于预测仓位伸展系数以上的情况，我们将仓位直接设置为杠杆上限。假设 L 为杠杆上限， k 为伸展系数，仓位转换具体数学表达式如下：

$$\min\left(\frac{L}{k} \times |x|, L\right)$$

我们采用这种方法转换仓位是因为我们假定模型的使用者在投资前不知道模型预测的仓位范围，因此我们设置了一个模型较为普遍的预测仓位范围进行相对杠杆范围的折叠，以便于投资者迅速决策和交易。

我们的单因子策略为多空策略，可能会在多头与空头方向开仓，仓位均采用模型输出预测值线性伸展后的结果。

2.2. 特征提取及特征转换

由于特征数量过多，考虑到机器学习模型的训练表现，我们在进行数据输入机器学习模型前，采用主成分分析进行特征分类降维或采用单因子回归显著性判断挑选之后输入堆栈式自编码器（SAE）进行特征降维。

其中，主成分分析创新性采用了分类降维的方法，将量价特征，基差特征，宏观特征以及利率期限结构特征等分类后，分别进行主成分分析降维，选择解释每个因子类别方差超过 90% 的所有成分输入到后续训练模型中。

单因子回归模型表达式为：

$$y_t = ax_t + b$$

其中 a 为斜率， b 为截距，采用最小二乘法进行估计，损失函数为：

$$L(y, \hat{y}) = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

主成分分析模型中，我们假设存在 p 个特征，整个数据样本可表示为如下矩阵：

$$X = (X_1, X_2, \dots, X_p)^T$$

其中：

$$X_i = (x_{i1}, x_{i2}, \dots, x_{in}); i = 1, 2, 3, \dots, p$$

我们希望通过正交矩阵 A 线性变换原数据样本矩阵，生成新的特征矩阵 Y ：

$$Y = AX$$

在新生成的特征矩阵 Y 中选择解释原数据方差超过一定比例的主成分达到降维目的。

2.3. 损失函数介绍

目前国内的机器学习研报和策略，多采取均方误差预测价格。本报告创新性采用了基于仓位预测的均方误差以及自定义的夏普损失的方式，改良了神经网络的表现。

由于同业常用的均方误差预测价格用于期货预测时，根据移仓换月时不同的机构的复权计算方法，容易造成输入数据的较大差异，远不如收益率数据作为模型被解释变量准确，但均方误差直接预测日收益率容易导致机器学习模型失效（直接预测出常数）。

本报告采用均方误差预测调整波动率后的日收益率，并将其作为仓位信号使用的逻辑体系，解决了机器学习模型均方误差直接预测收益率容易失效的问题。

夏普比率就是一个可以同时收益与风险加以综合考虑的经典指标，夏普损失可以体现这个比率值的大小，本报告自定义夏普损失表达式为：

$$L(\theta) = - \frac{\frac{1}{M} \sum_{\Omega} (\frac{1}{t} \sum_0^t y_{pred}(i, t) * \frac{y_{true}(i, t)}{\sigma})}{\sqrt{\frac{1}{M} \sum_{\Omega} (\frac{1}{t} \sum_0^t y_{pred}(i, t) * \frac{y_{true}(i, t)}{\sigma})^2 - (\frac{1}{M} \sum_{\Omega} (\frac{1}{t} \sum_0^t y_{pred}(i, t) * \frac{y_{true}(i, t)}{\sigma}))^2}}$$

基于仓位预测的均方误差损失表达式为：

$$L(\theta) = \sum_{\Omega} (y_{pred}(i, t) - \frac{y_{true}(i, t)}{\sigma})^2$$

2.4. 模型结构介绍

本报告对同业常用的模型结构进行了革新，尝试结合因子筛选/自编码器（SAE）/主成分分析（PCA）等降维方法，以及长短期记忆网络（LSTM），门循环单元（GRU）以及卷积神经网络（CNN）等深度学习模型。

神经网络结构搭建遵循的逻辑是经典模型基础上采用深度优先原则。通常在基础模型（如单层神经网络模型）有效的情况下，增加网络深度。深度并非盲目堆积，而是在浅层网络有效的基础上，增加深度，从而增加模型的准确率。神经网络结构也在参考相关的经典论文的基础上遍历更多可能性。

我们采用以及评估了不同降维方法（因子筛选/自编码器/主成分分析）对长短期记忆网络模型（LSTM），门控循环单元模型（GRU），长短期记忆网络与卷积神经网络混合模型（LSTM+CNN），长短期记忆网络与门控循环单元混合模型（LSTM+GRU）的策略表现提升作用。本报告对神经网络模型的每层附带 10% 的随机失活。

图表 8：模型结构设置

名称	层名
GRU	门循环单元（三层）+全连接层（两层）
LSTM	长短期记忆网络（三层）+全连接层（两层）
LSTM+CNN	长短期记忆网络（一层）+卷积层（一层）+池化层（一层）+长短期记忆网络（两层）+全连接层（两层）
LSTM+GRU	长短期记忆网络（一层）+门循环单元（两层）+全连接层（两层）

资料来源：东证衍生品研究院

2.5. 模型调参介绍

我们主要使用了 keras 的 Callback（回调函数）以及 ModelCheckpoint 功能来完成网络搭建和调参。Callbacks 是一个函数的合集，会在训练的阶段中所使用，可以用来查看训练模型的内在状态和统计。我们可以传递一个列表的 Callbacks 到 Sequential 或 Model 类型的 .fit() 方法。在训练时，相应的回调函数的方法就会被在各自的阶段被调用。而 ModelCheckpoint 是一个特定的回调函数，它的作用是在每次训练后保存模型以及自定义文件名称到指定文件夹。因此，它们可以用于保存在训练中训练集损失以及测试集损失

较小的模型，之后我们可以通过查阅训练集损失最少的神经元组合的训练以及测试的损失趋势，选择趋势明显的神经元组合。

在调参方面，我们采用不同降维方式以及模型超参数设置对模型进行循环遍历和运行，选用在策略训练集以及测试集表现最优的模型。策略框架中，对于每种降维方式下的每一个模型，在神经元组合/epoch/batch size 等方面，我们分别考虑了超过 100 种参数组合，并对每种参数组合进行了 50 次训练并计算出每次训练中模型训练集，测试集以及跟踪集的指标表现，选择训练集以及测试集指标均较良好的模型，并用跟踪集指标评估模型表现优劣。

所有网络不参与调参的超参数包含随机失活的概率（0.1），模型的优化器（Adam），损失函数（MSE 或夏普损失），LSTM/GRU 的门函数（sigmoid），以及激活函数（relu 或 sigmoid）。

图表 9：十年期国债期货（T）模型参数设置

损失类型	名称	超参数设置（神经元组合/epoch/batch size）
夏普损失	GRU	[200, 66, 22, 7, 1]/e47/b50
	LSTM	[100, 20, 4, 1, 1]/e2/b10
	LSTM_CNN	[100, 50, 25, 12, 6, 1]/e40/b30
	LSTM_GRU	[100, 33, 11, 3, 1]/e31/b20
	PCA+GRU	[100, 50, 25, 12, 1]/e19/b20
	PCA+LSTM	[100, 20, 4, 1, 1]/e17/b10
	PCA+LSTM_CNN	[150, 75, 37, 18, 9, 1]/e45/b30
	PCA+LSTM_GRU	[200, 66, 22, 7, 1]/e2/b50
	SAE+GRU	[150, 30, 6, 1, 1]/e19/b30
	SAE+LSTM	[150, 50, 16, 5, 1]/e18/b50
	SAE+LSTM_CNN	NA
	SAE+LSTM_GRU	[100, 50, 25, 12, 1]/e3/b30
均方误差损失	GRU	[100, 20, 4, 1, 1]/e12/b10
	LSTM	[100, 50, 25, 12, 1]/e49/b50
	LSTM_CNN	[150, 50, 16, 5, 1, 1]/e17/b10
	LSTM_GRU	[200, 66, 22, 7, 1]/e19/b30
	PCA+GRU	[150, 50, 16, 5, 1]/e43/b10
	PCA+LSTM	[200, 100, 50, 25, 1]/e24/b30
	PCA+LSTM_CNN	[100, 33, 11, 3, 1, 1]/e15/b30
	PCA+LSTM_GRU	[100, 50, 25, 12, 1]/e33/b20
	SAE+GRU	[100, 20, 4, 1, 1]/e25/b30
	SAE+LSTM	[200, 40, 8, 1, 1]/e18/b20
	SAE+LSTM_CNN	[150, 50, 16, 5, 1, 1]/e34/b50
	SAE+LSTM_GRU	[200, 40, 8, 1, 1]/e5/b30

资料来源：东证衍生品研究院

图表 10: 五年期国债期货 (TF) 模型参数设置

损失类型	名称	超参数设置 (神经元等/epoch/batch size)
夏普损失	GRU	[100, 33, 11, 3, 1]/e8/b20
	LSTM	[100, 33, 11, 3, 1]/e7/b10
	LSTM_CNN	[200, 66, 22, 7, 2, 1]/e4/b10
	LSTM_GRU	[100, 33, 11, 3, 1]/e27/b50
	PCA+GRU	[200, 66, 22, 7, 1]/e2/b50
	PCA+LSTM	[150, 30, 6, 1, 1]/e8/b50
	PCA+LSTM_CNN	[100, 50, 25, 12, 6, 1]/e50/b50
	PCA+LSTM_GRU	[100, 33, 11, 3, 1]/e16/b10
	SAE+GRU	[200, 40, 8, 1, 1]/e31/b30
	SAE+LSTM	[100, 50, 25, 12, 1]/e30/b50
	SAE+LSTM_CNN	[100, 50, 25, 12, 6, 1]/e35/b30
	SAE+LSTM_GRU	[100, 33, 11, 3, 1]/e48/b30
均方误差损失	GRU	[100, 33, 11, 3, 1]/e34/b10
	LSTM	[150, 50, 16, 5, 1]/e2/b20
	LSTM_CNN	[200, 100, 50, 25, 12, 1]/e14/b10
	LSTM_GRU	[100, 20, 4, 1, 1]/e18/b30
	PCA+GRU	[100, 50, 25, 12, 1]/e23/b50
	PCA+LSTM	[150, 50, 16, 5, 1]/e28/b30
	PCA+LSTM_CNN	[200, 100, 50, 25, 12, 1]/e42/b10
	PCA+LSTM_GRU	[100, 33, 11, 3, 1]/e45/b10
	SAE+GRU	[200, 66, 22, 7, 1]/e4/b30
	SAE+LSTM	[200, 100, 50, 25, 1]/e30/b10
	SAE+LSTM_CNN	[200, 100, 50, 25, 12, 1]/e35/b50
	SAE+LSTM_GRU	[150, 50, 16, 5, 1]/e21/b30

资料来源: 东证衍生品研究院

图表 11: 国债期货价差 (2TF-T) 模型参数设置

损失类型	名称	超参数设置 (神经元等/epoch/batch size)
夏普损失	GRU	[200, 100, 50, 25, 1]/e2/b50
	LSTM	[200, 66, 22, 7, 1]/e1/b50
	LSTM_CNN	[150, 50, 16, 5, 1, 1]/e22/b50
	LSTM_GRU	[150, 30, 6, 1, 1]/e15/b50
	PCA+GRU	[100, 20, 4, 1, 1]/e48/b30
	PCA+LSTM	[100, 20, 4, 1, 1]/e14/b20
	PCA+LSTM_CNN	[150, 30, 6, 1, 1, 1]/e2/b50

	PCA+LSTM_GRU	[100, 20, 4, 1, 1]/e17/b20
	SAE+GRU	[100, 50, 25, 12, 1]/e46/b50
	SAE+LSTM	[100, 33, 11, 3, 1]/e3/b50
	SAE+LSTM_CNN	[200, 66, 22, 7, 2, 1]/e2/b50
	SAE+LSTM_GRU	NA
均方误差损失	GRU	[150, 30, 6, 1, 1]/e46/b20
	LSTM	[200, 66, 22, 7, 1]/e29/b10
	LSTM_CNN	[150, 75, 37, 18, 9, 1]/e30/b50
	LSTM_GRU	[150, 75, 37, 18, 1]/e13/b10
	PCA+GRU	[150, 75, 37, 18, 1]/e50/b50
	PCA+LSTM	[150, 75, 37, 18, 1]/e4/b10
	PCA+LSTM_CNN	[100, 20, 4, 1, 1, 1]/e9/b10
	PCA+LSTM_GRU	[100, 33, 11, 3, 1]/e20/b20
	SAE+GRU	[150, 50, 16, 5, 1]/e32/b10
	SAE+LSTM	[200, 100, 50, 25, 1]/e22/b10
	SAE+LSTM_CNN	[200, 100, 50, 25, 12, 1]/e33/b20
	SAE+LSTM_GRU	[100, 50, 25, 12, 1]/e17/b50

资料来源：东证衍生品研究院

3. 模型结果

3.1. 损失函数结果对比

我们以 T/TF/2TF-T 的多头收益为业绩基准，以单因子回归筛选显著因子并将显著因子填入模型进行训练的模式为例，比较和评估了以夏普优化与均方误差优化的多空交易策略模型在训练集，测试集以及跟踪集上的表现。十年期国债期货（T）以 2015-3-27 至 2020-7-9 数据为训练集，2020-7-10 至 2021-8-24 数据为测试集，2021-8-25 至 2022-10-20 数据为跟踪集；五年期国债期货（TF）以 2013-9-13 至 2020-1-21 数据为训练集，2020-1-22 至 2021-6-8 数据为测试集，2021-6-9 至 2022-10-21 数据为跟踪集；国债期货跨品种价差（2TF-T）以 2015-9-9 至 2020-8-27 数据为训练集，2020-8-28 至 2021-9-17 数据为测试集，2021-6-9 至 2022-10-21 数据为跟踪集。

总体来看，夏普损失优化与均方误差损失优化的表现各有千秋：夏普损失优化模型与均方误差的优化模型均相对业绩基准在测试集与跟踪集上均相对业绩基准有不同程度的提高。夏普损失优化与均方误差优化在模型策略体系下均可能拟合出表现较好的模型，我们可以在最终的混合策略中将较好表现的模型结合。

图表 12：损失函数结果比较

品种	优化方法	模型	测试集夏普比率	跟踪集夏普比率
T	业绩基准		1.02	0.83
	夏普优化	LSTM	1.97	1.26

		GRU	2.31	1.67
		LSTM_CNN	1.82	1.29
		LSTM_GRU	1.28	1.13
	均方误差优化	LSTM	1.73	1.41
		GRU	2.96	1.46
		LSTM_CNN	1.74	1.79
		LSTM_GRU	2.76	1.20
TF	业绩基准		0.45	1.41
	夏普优化	LSTM	0.61	1.82
		GRU	0.79	1.89
		LSTM_CNN	1.11	1.70
		LSTM_GRU	0.69	1.76
	均方误差优化	LSTM	0.79	2.00
		GRU	1.23	2.37
		LSTM_CNN	0.96	1.80
		LSTM_GRU	1.04	2.05
TS	业绩基准		1.02	0.61
	夏普优化	LSTM	1.24	0.82
		GRU	1.58	1.07
		LSTM_CNN	2.07	1.72
		LSTM_GRU	2.03	0.73
	均方误差优化	LSTM	1.54	1.25
		GRU	1.65	1.18
		LSTM_CNN	1.37	1.19
		LSTM_GRU	1.89	1.11

资料来源:东证衍生品研究院,十年期国债期货(T)以2015-3-27至2020-7-9数据为训练集,2020-7-10至2021-8-24数据为测试集,2021-8-25至2022-10-20数据为跟踪集;五年期国债期货(TF)以2013-9-13至2020-1-21数据为训练集,2020-1-22至2021-6-8数据为测试集,2021-6-9至2022-10-21数据为跟踪集;国债期货跨品种价差(2TF-T)以2015-9-9至2020-8-27数据为训练集,2020-8-28至2021-9-17数据为测试集,2021-6-9至2022-10-21数据为跟踪集。

图表 13: 十年期国债期货 (T) 业绩基准表现指标

指标	训练集	测试集	跟踪集
总收益	11.00%	3.42%	2.54%
年化收益率	2.06%	3.12%	2.31%
年化波动率	4.20%	3.05%	2.79%
最大回撤率	-7.02%	-2.37%	-1.79%
胜率(D)	51.56%	51.45%	52.75%
盈亏比	1.03	1.11	1.03

夏普比率	0.49	1.02	0.83
Calmar 比	0.29	1.31	1.29

资料来源:东证衍生品研究院,2015-3-27 至 2020-7-9 数据为训练集,2020-7-10 至 2021-8-24 数据为测试集,2021-8-25 至 2022-10-20 数据为跟踪集

图表 14: 十年期国债期货 (T) 各模型表现指标

损失类型	模型	时间段	总收益	年化收益率	年化波动率	最大回撤率	胜率(D)	盈亏比	夏普比率	Calmar 比
夏普损失	LSTM	训练集	30.24%	5.30%	6.84%	-10.38%	51.56%	1.09	0.77	0.51
		测试集	6.05%	5.51%	2.80%	-1.19%	51.45%	1.37	1.97	4.61
		跟踪集	4.31%	3.91%	3.09%	-2.02%	52.75%	1.15	1.26	1.94
	GRU	训练集	71.17%	11.08%	4.95%	-4.84%	51.56%	1.63	2.24	2.29
		测试集	5.63%	5.13%	2.22%	-0.89%	51.45%	1.73	2.31	5.75
		跟踪集	4.83%	4.39%	2.63%	-1.40%	52.75%	1.35	1.67	3.13
	LSTM_CNN	训练集	21.06%	3.81%	5.69%	-11.06%	51.56%	1.09	0.67	0.34
		测试集	8.66%	7.88%	4.34%	-1.81%	51.45%	1.27	1.82	4.36
		跟踪集	6.02%	5.46%	4.23%	-2.12%	52.75%	1.12	1.29	2.58
	LSTM_GRU	训练集	37.09%	6.36%	11.99%	-14.60%	51.56%	1.09	0.53	0.44
		测试集	12.53%	11.38%	8.92%	-4.11%	51.45%	1.18	1.28	2.77
		跟踪集	13.11%	11.86%	10.52%	-5.50%	52.75%	1.08	1.13	2.16
均方误差损失	LSTM	训练集	438.28%	38.97%	5.74%	-2.30%	51.56%	3.63	6.79	16.97
		测试集	8.38%	7.63%	4.40%	-2.29%	51.45%	1.26	1.73	3.34
		跟踪集	6.85%	6.21%	4.41%	-2.23%	52.75%	1.14	1.41	2.79
	GRU	训练集	55.66%	9.04%	4.22%	-6.56%	51.56%	1.61	2.14	1.38
		测试集	8.69%	7.91%	2.68%	-0.98%	51.45%	1.99	2.96	8.04
		跟踪集	4.55%	4.13%	2.82%	-1.64%	52.75%	1.28	1.46	2.51
	LSTM_CNN	训练集	96.38%	14.10%	5.10%	-4.88%	51.56%	1.57	2.76	2.89
		测试集	3.43%	3.13%	1.91%	-1.04%	51.45%	1.32	1.64	3.00
		跟踪集	4.60%	4.18%	2.33%	-1.22%	52.75%	1.34	1.79	3.41
	LSTM_GRU	训练集	93.84%	13.81%	6.86%	-7.53%	51.56%	1.38	2.01	1.84
		测试集	9.52%	8.66%	4.92%	-3.31%	51.45%	1.26	1.76	2.62
		跟踪集	6.37%	5.78%	4.81%	-2.84%	52.75%	1.10	1.20	2.03

资料来源:东证衍生品研究院,2015-3-27 至 2020-7-9 数据为训练集,2020-7-10 至 2021-8-24 数据为测试集,2021-8-25 至 2022-10-20 数据为跟踪集

图表 15: 五年期国债期货 (TF) 业绩基准表现指标

指标	训练集	测试集	跟踪集
总收益	5.12%	1.72%	3.43%

年化收益率	0.82%	1.30%	2.60%
年化波动率	3.03%	2.87%	1.84%
最大回撤率	-5.36%	-4.62%	-1.26%
胜率(D)	52.13%	51.98%	52.13%
盈亏比	0.97	1.00	1.16
夏普比率	0.27	0.45	1.41
Calmar 比	0.15	0.28	2.06

资料来源：东证衍生品研究院，2013-9-13 至 2020-1-21 数据为训练集，2020-1-22 至 2021-6-8 数据为测试集，2021-6-9 至 2022-10-21 数据为跟踪集

图表 16：五年期国债期货（TF）各模型表现指标

损失类型	模型	时间段	总收益	年化收益率	年化波动率	最大回撤率	胜率(D)	盈亏比	夏普比率	Calmar 比
夏普损失	LSTM	训练集	12.83%	1.98%	4.52%	-7.89%	52.13%	1.02	0.44	0.25
		测试集	4.03%	3.05%	5.03%	-7.15%	51.98%	1.05	0.61	0.43
		跟踪集	7.83%	5.89%	3.23%	-1.90%	52.13%	1.25	1.82	3.10
	GRU	训练集	31.04%	4.50%	3.57%	-2.78%	52.13%	1.22	1.26	1.62
		测试集	4.63%	3.49%	4.44%	-6.61%	51.98%	1.10	0.79	0.53
		跟踪集	7.18%	5.41%	2.86%	-1.88%	52.13%	1.29	1.89	2.88
	LSTM_CNN	训练集	7.38%	1.17%	3.85%	-6.89%	52.13%	0.99	0.30	0.17
		测试集	5.12%	3.87%	3.48%	-3.71%	51.98%	1.32	1.11	1.04
		跟踪集	6.47%	4.87%	2.87%	-2.11%	52.13%	1.25	1.70	2.31
	LSTM_GRU	训练集	16.70%	2.54%	2.61%	-3.82%	52.13%	1.19	0.97	0.67
		测试集	3.44%	2.60%	3.76%	-6.48%	51.98%	1.11	0.69	0.40
		跟踪集	7.81%	5.88%	3.34%	-1.91%	52.13%	1.24	1.76	3.08
均方误差损失	LSTM	训练集	9.14%	1.43%	4.87%	-11.31%	52.13%	0.98	0.29	0.13
		测试集	4.71%	3.55%	4.52%	-5.61%	51.98%	1.10	0.79	0.63
		跟踪集	8.93%	6.71%	3.36%	-2.06%	52.13%	1.31	2.00	3.26
	GRU	训练集	202.97%	19.76%	3.70%	-2.06%	52.13%	2.96	5.35	9.59
		测试集	7.78%	5.85%	4.75%	-5.53%	51.98%	1.16	1.23	1.06
		跟踪集	9.78%	7.34%	3.10%	-1.62%	52.13%	1.40	2.37	4.52
	LSTM_CNN	训练集	11.23%	1.75%	4.69%	-9.65%	52.13%	1.00	0.37	0.18
		测试集	5.92%	4.46%	4.66%	-6.56%	51.98%	1.12	0.96	0.68
		跟踪集	8.16%	6.14%	3.42%	-2.55%	52.13%	1.24	1.80	2.40
	LSTM_GRU	训练集	57.24%	7.64%	3.91%	-4.06%	52.13%	1.33	1.95	1.88
		测试集	5.96%	4.49%	4.33%	-5.56%	51.98%	1.15	1.04	0.81
		跟踪集	8.04%	6.04%	2.95%	-1.95%	52.13%	1.32	2.05	3.10

资料来源：东证衍生品研究院，2013-9-13 至 2020-1-21 数据为训练集，2020-1-22 至 2021-6-8 数据为测试集，2021-6-9 至 2022-10-21 数据为跟踪集

图表 17: 国债期货价差 (2TF-T) 业绩基准表现指标

指标	训练集	测试集	跟踪集
总收益	1.84%	1.55%	0.89%
年化收益率	0.38%	1.51%	0.86%
年化波动率	1.93%	1.47%	1.42%
最大回撤率	-4.09%	-1.25%	-1.36%
胜率(D)	51.42%	54.12%	54.09%
盈亏比	0.98	1.01	0.94
夏普比率	0.20	1.02	0.61
Calmar 比	0.09	1.20	0.64

资料来源: 东证衍生品研究院, 2015-9-9 至 2020-8-27 数据为训练集, 2020-8-28 至 2021-9-17 数据为测试集, 2021-6-9 至 2022-10-21 数据为跟踪集

图表 18: 国债期货价差 (2TF-T) 各模型表现指标

损失类型	模型	时间段	总收益	年化收益率	年化波动率	最大回撤率	胜率(D)	盈亏比	夏普比率	Calmar 比
夏普损失	LSTM	训练集	6.92%	1.40%	3.04%	-5.33%	51.42%	1.06	0.46	0.26
		测试集	3.61%	3.52%	2.83%	-2.11%	54.12%	1.06	1.24	1.66
		跟踪集	2.10%	2.04%	2.50%	-2.36%	54.09%	0.98	0.82	0.86
	GRU	训练集	4.67%	0.96%	2.63%	-6.80%	51.30%	1.04	0.36	0.14
		测试集	1.97%	1.92%	1.21%	-0.84%	54.12%	1.13	1.58	2.29
		跟踪集	1.52%	1.47%	1.37%	-0.91%	53.91%	1.06	1.07	1.62
	LSTM_CNN	训练集	6.09%	1.24%	2.32%	-4.93%	51.34%	1.08	0.53	0.25
		测试集	1.14%	1.11%	0.54%	-0.26%	54.12%	1.75	2.07	4.28
		跟踪集	1.22%	1.18%	0.68%	-0.17%	53.91%	1.71	1.72	6.98
	LSTM_GRU	训练集	12.72%	2.52%	2.95%	-6.14%	51.42%	1.18	0.86	0.41
		测试集	3.95%	3.84%	1.89%	-0.66%	54.33%	1.34	2.03	5.82
		跟踪集	1.71%	1.65%	2.27%	-1.44%	53.91%	0.99	0.73	1.15
均方误差损失	LSTM	训练集	19.42%	3.76%	2.85%	-5.47%	51.39%	1.32	1.32	0.69
		测试集	3.69%	3.59%	2.33%	-1.02%	54.12%	1.13	1.54	3.54
		跟踪集	3.19%	3.09%	2.48%	-1.56%	54.09%	1.07	1.25	1.98
	GRU	训练集	69.88%	11.66%	2.54%	-0.99%	51.22%	3.52	4.58	11.81
		测试集	3.86%	3.75%	2.27%	-1.44%	54.12%	1.15	1.65	2.61
		跟踪集	2.97%	2.88%	2.44%	-1.90%	54.09%	1.06	1.18	1.52
	LSTM_CNN	训练集	6.15%	1.25%	3.38%	-9.66%	51.38%	1.03	0.37	0.13
		测试集	3.56%	3.46%	2.52%	-1.10%	54.12%	1.10	1.37	3.16
		跟踪集	2.89%	2.80%	2.35%	-2.29%	54.09%	1.06	1.19	1.22
	LSTM_GRU	训练集	7.47%	1.51%	2.72%	-6.47%	51.43%	1.08	0.56	0.23
		测试集	3.01%	2.93%	1.54%	-0.66%	54.12%	1.29	1.89	4.43

		跟踪集	2.33%	2.26%	2.03%	-1.13%	54.09%	1.09	1.11	1.99
--	--	-----	-------	-------	-------	--------	--------	------	------	------

资料来源:东证衍生品研究院,2015-9-9至2020-8-27数据为训练集,2020-8-28至2021-9-17数据为测试集,2021-6-9至2022-10-21数据为跟踪集

3.2. 降维结果比较评估

本报告尝试并比较了特征分类PCA降维以及单特征回归挑选显著特征进行SAE降维之后,再将降维后的新特征放入深度学习模型进行训练以评估两种降维方法:对于十年期国债期货(T)来说,PCA降维总体效果优于SAE;对于五年期国债期货(TF)来说,对夏普损失优化模型SAE降维总体效果优于PCA,对均方误差损失优化模型PCA降维总体效果优于SAE;对于国债期货价差(2TF-T)来说,PCA降维总体效果优于SAE。因此我们选用这些降维方法的时候,不能仅追求更复杂的降维方法,不同的降维方法在具体模型上的优劣仍需要根据拟合结果决定。

对于十年期国债期货(T)来说,PCA降维总体效果优于SAE:在测试集上,PCA降维的夏普损失优化模型仅PCA+LSTM_GRU模型夏普比率提高,PCA降维的均方误差的优化模型夏普比率均没有提高;在跟踪集上,PCA降维的夏普损失优化模型与PCA降维的均方误差的优化模型夏普比率均有提高。在测试集上,SAE降维的夏普损失优化模型仅SAE+LSTM_GRU模型有提高,SAE降维的均方误差的优化模型均没有提高;在跟踪集上,SAE降维的夏普损失优化模型仅SAE+GRU与SAE+LSTM_GRU有提高,SAE降维的均方误差的优化模型仅SAE+GRU与SAE+LSTM_GRU有提高。

图表 19: 十年期国债期货(T)降维情况比较

优化方法	模型	测试集夏普比率	跟踪集夏普比率
夏普损失优化	LSTM	1.97	1.26
	GRU	2.31	1.67
	LSTM_CNN	1.82	1.29
	LSTM_GRU	1.28	1.13
	PCA+LSTM	1.78	1.65
	PCA+GRU	1.71	1.72
	PCA+LSTM_CNN	1.54	1.35
	PCA+LSTM_GRU	2.19	1.52
	SAE+LSTM	1.46	1.53
	SAE+GRU	1.34	1.09
	SAE+LSTM_CNN	NA	NA
	SAE+LSTM_GRU	1.62	1.46
均方误差优化	LSTM	1.73	1.41
	GRU	2.96	1.46
	LSTM_CNN	1.74	1.79
	LSTM_GRU	2.76	1.20
	PCA+LSTM	1.73	1.62

	PCA+GRU	1.64	1.67
	PCA+LSTM_CNN	1.54	1.76
	PCA+LSTM_GRU	1.57	1.60
	SAE+LSTM	1.66	1.47
	SAE+GRU	1.38	1.44
	SAE+LSTM_CNN	1.30	1.60
	SAE+LSTM_GRU	1.55	1.81

资料来源：东证衍生品研究院，2015-3-27 至 2020-7-9 数据为训练集，2020-7-10 至 2021-8-24 数据为测试集，2021-8-25 至 2022-10-20 数据为跟踪集

图表 20：十年期国债期货（T）主成分分析降维后各模型表现指标

损失类型	模型	时间段	总收益	年化收益率	年化波动率	最大回撤率	胜率(D)	盈亏比	夏普比率	Calmar 比
夏普损失	SAE+LSTM	训练集	11.52%	2.15%	4.01%	-7.02%	51.56%	1.09	0.54	0.31
		测试集	8.40%	7.65%	4.28%	-2.69%	51.45%	1.33	1.78	2.85
		跟踪集	7.59%	6.88%	4.17%	-3.13%	52.75%	1.22	1.65	2.20
	SAE+GRU	训练集	18.50%	3.37%	4.82%	-8.26%	51.56%	1.09	0.70	0.41
		测试集	8.01%	7.29%	4.27%	-4.09%	51.45%	1.26	1.71	1.78
		跟踪集	6.00%	5.44%	3.17%	-1.94%	52.75%	1.24	1.72	2.80
	SAE+LSTM_CNN	训练集	12.40%	2.31%	4.65%	-7.83%	51.56%	1.05	0.50	0.30
		测试集	7.70%	7.01%	4.55%	-2.35%	51.45%	1.22	1.54	2.98
		跟踪集	6.89%	6.25%	4.63%	-3.99%	52.75%	1.13	1.35	1.57
	SAE+LSTM_GRU	训练集	15.70%	2.89%	5.67%	-9.71%	51.56%	1.05	0.51	0.30
		测试集	7.45%	6.78%	3.09%	-1.55%	51.45%	1.40	2.19	4.38
		跟踪集	6.19%	5.61%	3.70%	-2.09%	52.75%	1.15	1.52	2.68
均方误差损失	SAE+LSTM	训练集	43.16%	7.27%	7.29%	-11.97%	51.56%	1.14	1.00	0.61
		测试集	7.35%	6.69%	3.86%	-2.20%	51.45%	1.29	1.73	3.04
		跟踪集	7.79%	7.06%	4.35%	-2.21%	52.75%	1.21	1.62	3.19
	SAE+GRU	训练集	392.99%	36.60%	5.61%	-2.85%	51.56%	3.65	6.53	12.85
		测试集	7.13%	6.49%	3.97%	-2.29%	51.45%	1.25	1.64	2.83
		跟踪集	7.63%	6.92%	4.14%	-2.21%	52.75%	1.21	1.67	3.13
	SAE+LSTM_CNN	训练集	95.77%	14.03%	5.68%	-6.51%	51.56%	1.48	2.47	2.15
		测试集	7.31%	6.65%	4.31%	-2.86%	51.45%	1.23	1.54	2.33
		跟踪集	6.90%	6.26%	3.55%	-1.76%	52.75%	1.25	1.76	3.55
	SAE+LSTM_GRU	训练集	32.08%	5.59%	7.43%	-13.68%	51.56%	1.09	0.75	0.41
		测试集	7.09%	6.45%	4.11%	-2.95%	51.45%	1.26	1.57	2.18
		跟踪集	7.40%	6.71%	4.20%	-2.44%	52.75%	1.19	1.60	2.74

资料来源：东证衍生品研究院，2015-3-27 至 2020-7-9 数据为训练集，2020-7-10 至 2021-8-24 数据为测试集，2021-8-25 至 2022-10-20 数据为跟踪集

图表 21：十年期国债期货（T）堆栈自编码器降维后各模型表现指标

损失类型	模型	时间段	总收益	年化收益率	年化波动率	最大回撤率	胜率(D)	盈亏比	夏普比率	Calmar 比
夏普损失	SAE+LSTM	训练集	36.55%	6.28%	6.57%	-8.86%	51.56%	1.12	0.96	0.71
		测试集	6.98%	6.36%	4.34%	-2.40%	51.45%	1.22	1.46	2.65
		跟踪集	6.81%	6.18%	4.04%	-2.52%	52.75%	1.17	1.53	2.46
	SAE+GRU	训练集	23.64%	4.24%	8.31%	-14.79%	51.56%	1.03	0.51	0.29
		测试集	8.76%	7.97%	5.97%	-4.10%	51.45%	1.16	1.34	1.94
		跟踪集	6.50%	5.90%	5.40%	-3.16%	52.75%	1.07	1.09	1.86
	SAE+LSTM_CNN	训练集	NA	NA	NA	NA	NA	NA	NA	NA
		测试集	NA	NA	NA	NA	NA	NA	NA	NA
		跟踪集	NA	NA	NA	NA	NA	NA	NA	NA
	SAE+LSTM_GRU	训练集	31.37%	5.48%	6.04%	-7.53%	51.56%	1.12	0.91	0.73
		测试集	5.89%	5.36%	3.30%	-1.51%	51.45%	1.25	1.62	3.56
		跟踪集	5.69%	5.16%	3.53%	-1.88%	52.75%	1.16	1.46	2.75
均方误差损失	SAE+LSTM	训练集	33.59%	5.82%	4.70%	-6.96%	51.56%	1.24	1.24	0.84
		测试集	3.80%	3.47%	2.08%	-0.83%	51.45%	1.59	1.66	4.19
		跟踪集	2.83%	2.57%	1.75%	-1.32%	52.75%	1.30	1.47	1.95
	SAE+GRU	训练集	62.86%	10.00%	5.36%	-4.65%	51.56%	1.35	1.87	2.15
		测试集	7.17%	6.53%	4.74%	-2.78%	51.45%	1.19	1.38	2.35
		跟踪集	7.26%	6.59%	4.58%	-2.52%	52.75%	1.14	1.44	2.61
	SAE+LSTM_CNN	训练集	30.42%	5.33%	4.95%	-6.08%	51.56%	1.18	1.08	0.88
		测试集	6.61%	6.02%	4.65%	-2.80%	51.45%	1.20	1.30	2.15
		跟踪集	7.89%	7.15%	4.47%	-2.46%	52.75%	1.19	1.60	2.91
	SAE+LSTM_GRU	训练集	30.00%	5.26%	4.67%	-6.53%	51.56%	1.20	1.13	0.81
		测试集	4.60%	4.19%	2.71%	-1.45%	51.45%	1.41	1.55	2.89
		跟踪集	5.63%	5.11%	2.82%	-1.65%	52.75%	1.30	1.81	3.09

资料来源：东证衍生品研究院，2015-3-27 至 2020-7-9 数据为训练集，2020-7-10 至 2021-8-24 数据为测试集，2021-8-25 至 2022-10-20 数据为跟踪集

对于五年期国债期货（TF）来说，对夏普损失优化模型 SAE 降维总体效果优于 PCA，对均方误差损失优化模型 PCA 降维总体效果优于 SAE：在测试集上，PCA 降维的夏普损失优化模型与 PCA 降维的均方误差的优化模型均为仅 PCA+LSTM 模型有提高。在跟踪集上，PCA 降维的夏普损失优化模型中 PCA+LSTM，PCA+LSTM_CNN，PCA+LSTM_GRU 均有提高，PCA 降维的均方误差的优化模型均有小幅提高。在测试集上，SAE 降维的夏普损失优化模型仅 SAE+LSTM_GRU 模型有提高，SAE 降维的均方误差的优化模型中 SAE+LSTM 与 SAE+GRU 模型有提高。在跟踪集上，SAE 降维的夏普损失优化模型均有提高，SAE 降维的均方误差的优化模型均没有提高。

图表 22：五年期国债期货（TF）降维情况比较

优化方法	模型	测试集夏普比率	跟踪集夏普比率
夏普损失优化	LSTM	0.61	1.82
	GRU	0.79	1.89
	LSTM_CNN	1.11	1.70
	LSTM_GRU	0.69	1.76
	PCA+LSTM	0.86	1.98
	PCA+GRU	0.75	1.64
	PCA+LSTM_CNN	1.00	2.24
	PCA+LSTM_GRU	0.71	1.86
	SAE+LSTM	0.72	2.18
	SAE+GRU	0.68	1.98
	SAE+LSTM_CNN	0.69	2.15
	SAE+LSTM_GRU	1.30	2.08
均方误差优化	LSTM	0.79	2.00
	GRU	1.23	2.37
	LSTM_CNN	0.96	1.80
	LSTM_GRU	1.04	2.05
	PCA+LSTM	0.86	2.12
	PCA+GRU	1.18	2.38
	PCA+LSTM_CNN	0.79	2.08
	PCA+LSTM_GRU	1.00	2.13
	SAE+LSTM	1.81	1.84
	SAE+GRU	1.36	1.73
	SAE+LSTM_CNN	0.96	1.73
	SAE+LSTM_GRU	0.90	1.72

资料来源：东证衍生品研究院，2013-9-13 至 2020-1-21 数据为训练集，2020-1-22 至 2021-6-8 数据为测试集，2021-6-9 至 2022-10-21 数据为跟踪集

图表 23：五年期国债期货（TF）主成分分析降维后各模型表现指标

损失类型	模型	时间段	总收益	年化收益率	年化波动率	最大回撤率	胜率(D)	盈亏比	夏普比率	Calmar 比
夏普损失	SAE+LSTM	训练集	15.62%	2.39%	3.21%	-3.41%	52.13%	1.12	0.74	0.70
		测试集	4.95%	3.73%	4.32%	-5.32%	51.98%	1.12	0.86	0.70
		跟踪集	5.35%	4.04%	2.04%	-1.36%	52.13%	1.40	1.98	2.98
	SAE+GRU	训练集	10.42%	1.63%	3.81%	-4.94%	52.13%	1.01	0.43	0.33
		测试集	4.53%	3.42%	4.58%	-6.24%	51.98%	1.07	0.75	0.55
		跟踪集	7.23%	5.44%	3.32%	-1.93%	52.13%	1.22	1.64	2.83
	SAE+LSTM_CNN	训练集	24.65%	3.65%	4.19%	-6.11%	52.13%	1.10	0.87	0.60

均方 误差 损失		测试集	3.41%	2.58%	2.57%	-2.99%	51.98%	1.16	1.00	0.86
		跟踪集	5.23%	3.94%	1.76%	-1.01%	52.13%	1.57	2.24	3.90
		训练集	7.90%	1.24%	3.96%	-7.71%	52.13%	0.98	0.31	0.16
	SAE+LSTM_GRU	测试集	4.65%	3.51%	4.94%	-6.84%	51.98%	1.06	0.71	0.51
		跟踪集	7.71%	5.80%	3.12%	-1.67%	52.13%	1.27	1.86	3.47
		训练集	10.30%	1.61%	5.12%	-12.27%	52.13%	0.98	0.31	0.13
	SAE+LSTM	测试集	5.71%	4.30%	5.00%	-6.97%	51.98%	1.09	0.86	0.62
		跟踪集	9.67%	7.26%	3.42%	-2.40%	52.13%	1.32	2.12	3.03
		训练集	105.68%	12.45%	3.52%	-2.41%	52.13%	2.00	3.53	5.16
	SAE+GRU	测试集	6.64%	5.00%	4.23%	-5.15%	51.98%	1.16	1.18	0.97
		跟踪集	9.27%	6.96%	2.93%	-1.44%	52.13%	1.39	2.38	4.84
		训练集	17.21%	2.62%	5.50%	-8.67%	52.13%	1.01	0.48	0.30
	SAE+LSTM_CNN	测试集	4.08%	3.08%	3.88%	-5.61%	51.98%	1.10	0.79	0.55
		跟踪集	6.80%	5.12%	2.46%	-1.41%	52.13%	1.38	2.08	3.62
		训练集	14.03%	2.16%	5.09%	-10.90%	52.13%	1.01	0.42	0.20
	SAE+LSTM_GRU	测试集	6.02%	4.53%	4.55%	-5.23%	51.98%	1.12	1.00	0.87
		跟踪集	8.91%	6.69%	3.14%	-1.54%	52.13%	1.34	2.13	4.33
		训练集	8.91%	6.69%	3.14%	-1.54%	52.13%	1.34	2.13	4.33

资料来源：东证衍生品研究院，2013-9-13 至 2020-1-21 数据为训练集，2020-1-22 至 2021-6-8 数据为测试集，2021-6-9 至 2022-10-21 数据为跟踪集

图表 24：五年期国债期货（TF）堆栈自编码器降维后各模型表现指标

损失 类型	模型	时间段	总收益	年化收 益率	年化波 动率	最大回 撤率	胜率(D)	盈亏 比	夏普 比率	Calmar 比
夏普 损失	SAE+LSTM	训练集	9.00%	1.41%	3.57%	-7.55%	52.13%	1.01	0.40	0.19
		测试集	0.82%	0.62%	0.86%	-0.95%	51.98%	1.11	0.72	0.65
		跟踪集	4.85%	3.66%	1.68%	-0.54%	52.13%	1.50	2.18	6.73
	SAE+GRU	训练集	7.26%	1.15%	3.50%	-7.55%	52.13%	1.00	0.33	0.15
		测试集	0.84%	0.64%	0.93%	-0.95%	51.98%	1.16	0.68	0.68
		跟踪集	5.31%	4.01%	2.02%	-0.94%	52.13%	1.39	1.98	4.26
	SAE+LSTM_CNN	训练集	8.55%	1.34%	3.55%	-7.55%	52.13%	1.00	0.38	0.18
		测试集	0.89%	0.68%	0.99%	-0.95%	51.98%	1.15	0.69	0.72
		跟踪集	5.09%	3.84%	1.79%	-0.70%	52.13%	1.42	2.15	5.51
	SAE+LSTM_GRU	训练集	10.24%	1.60%	3.51%	-7.55%	52.13%	1.02	0.45	0.21
		测试集	2.02%	1.53%	1.18%	-0.95%	51.98%	1.36	1.30	1.61
		跟踪集	5.33%	4.02%	1.93%	-0.86%	52.13%	1.37	2.08	4.66
均方 误差 损失	SAE+LSTM	训练集	19.46%	2.94%	5.04%	-9.51%	52.13%	1.03	0.58	0.31
		测试集	6.60%	4.97%	2.74%	-1.91%	51.98%	1.43	1.81	2.59
		跟踪集	7.59%	5.71%	3.11%	-1.83%	52.13%	1.26	1.84	3.12
	SAE+GRU	训练集	25.93%	3.82%	3.79%	-6.35%	52.13%	1.16	1.01	0.60

		测试集	4.53%	3.42%	2.51%	-1.64%	51.98%	1.33	1.36	2.09
		跟踪集	7.38%	5.56%	3.22%	-2.24%	52.13%	1.23	1.73	2.48
	SAE+LSTM_CNN	训练集	15.12%	2.32%	5.27%	-10.91%	52.13%	1.01	0.44	0.21
		测试集	4.52%	3.42%	3.54%	-3.24%	51.98%	1.11	0.96	1.05
		跟踪集	6.71%	5.05%	2.93%	-2.21%	52.13%	1.24	1.73	2.28
	SAE+LSTM_GRU	训练集	17.28%	2.63%	5.41%	-10.98%	52.13%	1.01	0.49	0.24
		测试集	3.84%	2.90%	3.23%	-3.21%	51.98%	1.09	0.90	0.91
		跟踪集	7.04%	5.30%	3.08%	-2.01%	52.13%	1.23	1.72	2.63

资料来源：东证衍生品研究院，2013-9-13 至 2020-1-21 数据为训练集，2020-1-22 至 2021-6-8 数据为测试集，2021-6-9 至 2022-10-21 数据为跟踪集

对于国债期货价差（2TF-T）来说，PCA 降维总体效果优于 SAE：在测试集上，PCA 降维的夏普损失优化模型中 PCA+LSTM，PCA+GRU，PCA+LSTM_GRU 模型有提高，PCA 降维的均方误差的优化模型中 PCA+LSTM，PCA+GRU，PCA+LSTM_CNN 模型有提高。在跟踪集上，PCA 降维的夏普损失优化模型中 PCA+LSTM，PCA+GRU，PCA+LSTM_GRU 模型均有提高，PCA 降维的均方误差的优化模型中 PCA+GRU 和 PCA+LSTM_GRU 模型有提高。在测试集上，SAE 降维的夏普损失优化模型仅 SAE+LSTM 模型有提高，SAE 降维的均方误差的优化模型中 SAE+LSTM，SAE+GRU，SAE+LSTM_CNN 模型有提高。在跟踪集上，SAE 降维的夏普损失优化模型均未有提高，SAE 降维的均方误差的优化模型中 SAE+GRU，SAE+LSTM_CNN，SAE+LSTM_GRU 模型有提高。

图表 25：国债期货价差（2TF-T）降维情况比较

优化方法	模型	测试集夏普比率	跟踪集夏普比率
夏普损失优化	LSTM	1.24	0.82
	GRU	1.58	1.07
	LSTM_CNN	2.07	1.72
	LSTM_GRU	2.03	0.73
	PCA+LSTM	1.76	1.01
	PCA+GRU	1.80	1.80
	PCA+LSTM_CNN	1.78	1.35
	PCA+LSTM_GRU	2.46	1.95
	SAE+LSTM	1.34	0.82
	SAE+GRU	1.07	0.66
	SAE+LSTM_CNN	1.72	1.61
	SAE+LSTM_GRU	NA	NA
均方误差优化	LSTM	1.54	1.25
	GRU	1.65	1.18
	LSTM_CNN	1.37	1.19

	LSTM_GRU	1.89	1.11
	PCA+LSTM	1.75	1.22
	PCA+GRU	1.81	1.37
	PCA+LSTM_CNN	1.94	1.09
	PCA+LSTM_GRU	1.71	1.24
	SAE+LSTM	1.80	1.18
	SAE+GRU	1.85	1.27
	SAE+LSTM_CNN	2.22	1.33
	SAE+LSTM_GRU	1.84	1.23

资料来源：东证衍生品研究院，2015-9-9 至 2020-8-27 数据为训练集，2020-8-28 至 2021-9-17 数据为测试集，2021-6-9 至 2022-10-21 数据为跟踪集

图表 26：国债期货价差（2TF-T）主成分分析降维后各模型表现指标

损失类型	模型	时间段	总收益	年化收益率	年化波动率	最大回撤率	胜率 (D)	盈亏比	夏普比率	Calmar 比
夏普损失	SAE+LSTM	训练集	10.75%	2.15%	2.03%	-2.58%	51.52%	1.32	1.06	0.83
		测试集	1.49%	1.45%	0.83%	-0.24%	54.33%	1.68	1.76	6.06
		跟踪集	1.29%	1.25%	1.24%	-1.03%	53.91%	1.13	1.01	1.21
	SAE+GRU	训练集	25.73%	4.88%	2.14%	-1.56%	51.38%	1.73	2.28	3.12
		测试集	2.56%	2.49%	1.39%	-0.80%	54.12%	1.24	1.80	3.12
		跟踪集	3.40%	3.29%	1.83%	-1.11%	54.09%	1.23	1.80	2.95
	SAE+LSTM_CNN	训练集	14.74%	2.90%	3.31%	-5.12%	51.30%	1.16	0.88	0.57
		测试集	2.89%	2.81%	1.58%	-0.94%	54.12%	1.23	1.78	3.01
		跟踪集	2.26%	2.19%	1.62%	-1.33%	53.91%	1.15	1.35	1.65
	SAE+LSTM_GRU	训练集	16.97%	3.32%	2.19%	-2.87%	51.43%	1.45	1.51	1.15
		测试集	3.43%	3.33%	1.35%	-0.73%	54.12%	1.43	2.46	4.55
		跟踪集	3.63%	3.51%	1.80%	-1.47%	54.09%	1.26	1.95	2.39
均方误差损失	SAE+LSTM	训练集	10.48%	2.10%	2.76%	-7.67%	51.30%	1.16	0.76	0.27
		测试集	3.33%	3.24%	1.85%	-0.65%	54.12%	1.18	1.75	4.99
		跟踪集	3.08%	2.98%	2.43%	-1.49%	54.09%	1.05	1.22	2.00
	SAE+GRU	训练集	72.94%	12.07%	2.63%	-1.21%	51.47%	3.17	4.59	10.01
		测试集	4.44%	4.32%	2.38%	-1.59%	54.12%	1.20	1.81	2.72
		跟踪集	2.74%	2.66%	1.94%	-1.48%	54.09%	1.10	1.37	1.80
	SAE+LSTM_CNN	训练集	12.56%	2.49%	3.36%	-5.26%	51.38%	1.11	0.74	0.47
		测试集	4.01%	3.90%	2.01%	-0.79%	54.33%	1.23	1.94	4.91
		跟踪集	2.83%	2.75%	2.51%	-1.96%	54.09%	1.04	1.09	1.40
	SAE+LSTM_GRU	训练集	11.23%	2.24%	3.14%	-7.08%	51.38%	1.13	0.71	0.32
		测试集	3.58%	3.48%	2.03%	-1.01%	54.12%	1.18	1.71	3.43
		跟踪集	2.80%	2.72%	2.19%	-1.64%	54.09%	1.09	1.24	1.65

资料来源：东证衍生品研究院，2015-9-9 至 2020-8-27 数据为训练集，2020-8-28 至 2021-9-17 数据为测试集，2021-6-9 至 2022-10-21 数据为跟踪集

图表 27：国债期货价差（2TF-T）堆栈自编码器降维后各模型表现指标

损失类型	模型	时间段	总收益	年化收益率	年化波动率	最大回撤率	胜率(D)	盈亏比	夏普比率	Calmar 比
夏普损失	SAE+LSTM	训练集	3.86%	0.79%	2.07%	-4.20%	51.47%	1.02	0.38	0.19
		测试集	2.77%	2.69%	2.01%	-1.28%	54.12%	1.06	1.34	2.09
		跟踪集	1.35%	1.31%	1.60%	-1.40%	54.09%	0.98	0.82	0.94
	SAE+GRU	训练集	3.67%	0.75%	2.26%	-3.93%	51.26%	1.02	0.33	0.19
		测试集	0.95%	0.93%	0.87%	-0.69%	54.12%	1.02	1.07	1.34
		跟踪集	0.55%	0.53%	0.81%	-0.79%	54.09%	0.95	0.66	0.68
	SAE+LSTM_CNN	训练集	3.22%	0.66%	1.71%	-4.44%	51.39%	1.04	0.39	0.15
		测试集	1.37%	1.34%	0.78%	-0.42%	54.33%	1.22	1.72	3.19
		跟踪集	0.90%	0.88%	0.55%	-0.29%	53.91%	1.43	1.61	3.02
	SAE+LSTM_GRU	训练集	NA	NA	NA	NA	NA	NA	NA	NA
		测试集	NA	NA	NA	NA	NA	NA	NA	NA
		跟踪集	NA	NA	NA	NA	NA	NA	NA	NA
均方误差损失	SAE+LSTM	训练集	5.16%	1.05%	2.51%	-5.20%	51.38%	1.02	0.42	0.20
		测试集	3.52%	3.43%	1.91%	-0.77%	54.12%	1.15	1.80	4.46
		跟踪集	1.91%	1.85%	1.56%	-1.34%	54.09%	1.09	1.18	1.38
	SAE+GRU	训练集	6.28%	1.27%	2.28%	-3.95%	51.26%	1.07	0.56	0.32
		测试集	3.44%	3.35%	1.81%	-0.81%	54.12%	1.20	1.85	4.15
		跟踪集	1.84%	1.78%	1.40%	-1.24%	53.91%	1.22	1.27	1.43
	SAE+LSTM_CNN	训练集	7.90%	1.59%	2.07%	-3.06%	51.30%	1.10	0.77	0.52
		测试集	3.91%	3.80%	1.71%	-0.80%	54.12%	1.29	2.22	4.78
		跟踪集	1.95%	1.89%	1.42%	-1.10%	53.91%	1.18	1.33	1.71
	SAE+LSTM_GRU	训练集	4.68%	0.96%	2.61%	-6.09%	51.38%	1.02	0.37	0.16
		测试集	3.47%	3.38%	1.84%	-0.80%	54.12%	1.18	1.84	4.22
		跟踪集	1.85%	1.79%	1.46%	-1.31%	54.09%	1.14	1.23	1.36

资料来源：东证衍生品研究院，2015-9-9 至 2020-8-27 数据为训练集，2020-8-28 至 2021-9-17 数据为测试集，2021-6-9 至 2022-10-21 数据为跟踪集

3.3. 多模型混合策略展示

我们希望结合不同品种的不同模型的优点来进行多模型策略组合，根据每个品种的测试集及验证集综合表现最佳来挑选混合策略模型，最终推荐采用多模型混合策略：资金分配 70% 于 T 的 SAE+LSTM_GRU 均方误差损失优化模型(T 交易最活跃)，资金分配 15% 于 TF 的 PCA+GRU 均方误差损失优化模型，以及资金分配 15% 于 2TF-T 的 LSTM 均方

误差损失优化模型，我们分别以 2 倍，2.5 倍以及 3 倍杠杆进行策略业绩展示，投资者可根据实际风险偏好等进行资金分配以及杠杆选择的调整。

我们将 2015-9-9 至 2022-10-20 的混合策略表现作为其初始指标，将未参与混合策略挑选的 2022-10-20 至 2023-3-8 的混合策略表现作为跟踪指标，并将混合品种投资 (1/3 T+1/3 TF+1/3 (2TF-T)) 作为比较的业绩基准。

我们可以看见混合策略在 2 倍，2.5 倍以及 3 倍杠杆下，初始集上的夏普比率均为 1.28，优于业绩基准的 0.63；在跟踪集上的夏普比率分别为 1.31，1.33，1.34，优于业绩基准的 0.32，混合策略整体净值曲线也较为平滑。

图表 28：业绩基准指标

时间段	总收益	年化收益率	年化波动率	最大回撤率	胜率(D)	盈亏比	夏普比率	Calmar 比
业绩基准初始集	10.30%	1.44%	2.29%	-5.03%	52.20%	1.03	0.63	0.29
业绩基准跟踪集	0.21%	0.56%	1.67%	-1.03%	55.91%	0.84	0.34	0.55


资料来源：东证衍生品研究院，初始集时间 2015-9-9 至 2022-10-20，跟踪集时间为 2022-10-20 至 2023-3-8

图表 29：混合策略指标

杠杆率	时间段	总收益	年化收益率	年化波动率	最大回撤率	胜率(D)	盈亏比	夏普比率	Calmar 比
2.00	混合策略初始集	30.50%	3.96%	3.10%	-6.08%	52.37%	1.17	1.28	0.65
	混合策略跟踪集	0.94%	2.55%	1.95%	-0.86%	56.99%	0.97	1.31	2.98
2.50	混合策略初始集	45.25%	5.59%	4.36%	-8.45%	52.31%	1.17	1.28	0.66
	混合策略跟踪集	1.57%	4.27%	3.21%	-1.40%	56.99%	0.97	1.33	3.05
3.00	混合策略初始集	56.20%	6.72%	5.24%	-10.13%	52.37%	1.17	1.28	0.66
	混合策略跟踪集	1.89%	5.15%	3.85%	-1.67%	56.99%	0.98	1.34	3.08

资料来源：东证衍生品研究院，初始集时间 2015-9-9 至 2022-10-20，跟踪集时间为 2022-10-20 至 2023-3-8

图表 30：混合策略净值曲线



资料来源：东证衍生品研究院

4. 风险提示

量化模型失效风险，指标的有效性基于历史数据得出，不排除失效的可能。

期货走势评级体系（以收盘价的变动幅度为判断标准）

走势评级	短期（1-3 个月）	中期（3-6 个月）	长期（6-12 个月）
强烈看涨	上涨 15%以上	上涨 15%以上	上涨 15%以上
看涨	上涨 5-15%	上涨 5-15%	上涨 5-15%
震荡	振幅-5%-+5%	振幅-5%-+5%	振幅-5%-+5%
看跌	下跌 5-15%	下跌 5-15%	下跌 5-15%
强烈看跌	下跌 15%以上	下跌 15%以上	下跌 15%以上

上海东证期货有限公司

上海东证期货有限公司成立于 2008 年，是一家经中国证券监督管理委员会批准的经营期货业务的综合性公司。东证期货是东方证券股份有限公司全资子公司。公司主要从事商品期货经纪、金融期货经纪、期货交易咨询、资产管理、基金销售等业务，拥有上海期货交易所、大连商品交易所、郑州商品交易所、上海国际能源交易中心和广州期货交易所会员资格，是中国金融期货交易所全面结算会员。公司拥有东证润和资本管理有限公司，上海东祺投资管理有限公司和东证期货国际（新加坡）私人有限公司三家全资子公司。

自成立以来，东证期货秉承稳健经营、创新发展的宗旨，坚持以金融科技助力衍生品发展为主线，通过大数据、云计算、人工智能、区块链等金融科技手段打造研究和技术两大核心竞争力，坚持市场化、国际化、集团化发展方向，朝着建设一流衍生品服务商的目标继续前行。

免责声明

本报告由上海东证期货有限公司（以下简称“本公司”）制作及发布。

本研究报告仅供本公司的客户使用。本公司不会因接收人收到本报告而视其为本公司的当然客户。

本研究报告是基于本公司认为可靠的且目前已公开的信息撰写，本公司力求但不保证该信息的准确性和完整性，客户也不应该认为该信息是准确和完整的。同时，本公司不保证文中观点或陈述不会发生任何变更，在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。本公司会适时更新我们的研究，但可能会因某些规定而无法做到。除了一些定期出版的报告之外，绝大多数研究报告是在分析师认为适当的时候不定期地发布。

在任何情况下，本报告中的信息或所表述的意见并不构成对任何人的投资建议，也没有考虑到个别客户特殊的投资目标、财务状况或需求。客户应考虑本报告中的任何意见或建议是否符合其特定状况，若有必要应寻求专家意见。本报告所载的资料、工具、意见及推测只提供给客户作参考之用，并非作为或被视为出售或购买投资标的的邀请或向人作出邀请。

在任何情况下，本公司不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任，投资者需自行承担风险。

本报告主要以电子版形式分发，间或也会辅以印刷品形式分发，所有报告版权均归本公司所有。未经本公司事先书面授权，任何机构或个人不得以任何形式复制、转发或公开传播本报告的全部或部分内容，不得将报告内容作为诉讼、仲裁、传媒所引用之证明或依据，不得用于营利或用于未经允许的其它用途。

如需引用、刊发或转载本报告，需注明出处为东证衍生品研究院，且不得对本报告进行任何有悖原意的引用、删节和修改。

东证衍生品研究院

地址：上海市中山南路318号东方国际金融广场2号楼21楼

联系人：梁爽

电话：8621-63325888-1592

传真：8621-33315862

网址：www.orientfutures.com

Email：research@orientfutures.com